

Prezentace a analýza dat

AI first

Pro zpracování ocením využití AI nástrojů. Přesto je potřeba se nad zpracováním zamyslet a snažit se pochopit i výstupní data a grafy.

Zadání

V souboru *sklik_overview_sample.csv* je ukázkový datový vzorek o výkonu několika reklamních webů. Připravte přehled těchto dat pro produktově-byznysovou schůzku (není cílem nachystat dlouhodobý dashboard, ale jednorázově prezentovat data).

Výstup

Vizuální výstup - (PDF, printscreen, odkaz do nástroje, Jupyter ntb).

Stručný popis dat. Případně zamyšlení nad navazujícími analýzami (můžete popsat i další možné analýzy nad tímto samplem).

Cíl

Cílem je pochopit, co data říkají, a umět je dobře předat lidem, kteří v nich neumí tak dobře číst. Není zde potřeba velké množství grafů ani dělat důkladné analýzy (ty detailnější stačí popsat jako možné cesty k prozkoumání).

SQL znalosti

Bez AI

Prosím o nevyužívání AI ani vyhledávání funkcí

Zadání

Jeden z úkolů datového analytika je třeba umět kontrolovat SQL, které vedou k výstupu dat. Prosím o přečtení a pochopení SQL dotazu a zodpovězením otázek pod ním.

Cíl

Jedná se o ukázkový SQL dotaz střední náročnosti, který běžně generujeme v rámci naší práce a je důležitá schopnost tento dotaz umět rychle přečíst a pochopit.

SQL Dotaz

SELECT

-- Network (rozdělujeme výdej reklamy ve vyhledávání nebo bannerovou reklamu v obsahové síti).

o.NETWORK,

c.NAME AS CAMPAIGN_NAME,

COUNT(DISTINCT o.USER_ID),

-- Reklamy jsou v účtu dělené do struktury Kampaň -> Sestava (Groups) -> Samotná reklama).

COUNT(DISTINCT o.GROUP_ID),

SUM(o.IMPRESSIONS),

SUM(o.CLICKS),

SUM(o.MONEY),

ROUND(SUM(o.CLICKS) * 100.0 / NULLIF(SUM(o.IMPRESSIONS), 0), 2),

CASE

WHEN SUM(o.MONEY) >= 50000 THEN 'CAT 1'

WHEN SUM(o.MONEY) >= 5000 THEN 'CAT 2'

ELSE 'CAT 3'

END

FROM ADVERTISING.SKLIK.COMPLETE_OVERVIEW o

LEFT JOIN ADVERTISING.SKLIK_CAMPAIGN c

ON o.CAMPAIGN_ID = c.ID

WHERE o.DT >= DATEADD(day, -7, CURRENT_DATE)

AND o.DSP = 'sklik'

GROUP BY o.NETWORK, c.NAME

HAVING SUM(o.IMPRESSIONS) > 1000

ORDER BY SUM(o.IMPRESSIONS) DESC

LIMIT 20;

Otázky k zodpovězení

1. Co představuje jeden řádek výsledku a k jakému období se vztahuje?

2. Proč je použit `LEFT JOIN`, a ne `INNER JOIN`?
3. Jaký je rozdíl mezi `COUNT(DISTINCT o.USER\_ID)`, `COUNT(o.USER\_ID)` a `COUNT(\*)` — a proč by v tomhle dotazu dávalo použití špatné varianty zavádějící číslo?
4. K čemu slouží `NULLIF(SUM(o.IMPRESSIONS), 0)` ve výpočtu? Jaké chybě to předchází a co by se bez toho mohlo stát?
5. Proč je filtr na datum (`o.DT >= ...`) ve `WHERE`, ale filtr na objem (`SUM(o.IMPRESSIONS) > 1000`) až v `HAVING`? Šlo by je prohodit?
6. Co by se změnilo ve výsledku, kdyby `GROUP BY` obsahoval jen `o.NETWORK` (bez `c.NAME`)?
7. Jak funguje `CASE WHEN`? Proč záleží na pořadí podmínek (`>= 50000` před `>= 5000`) a co by se stalo, kdyby se prohodily? K čemu slouží větev `ELSE` a co by se stalo bez ní pro řádek, který nesplní žádnou `WHEN` podmínku?

Obecné analytické, deduktivní uvažování

Dvě rychlé otázky na zamyšlení. Prosím bez využití AI.

1/ Je možné z dat jednoznačně určit, který web měl na základě dat nejvíce prokliků?

Odůvodněte.

Web	Imprese	Konverze
zive.cz	310	58
aazdravi.cz	100	5
pocasi.cz	298	100
seznam.cz	658	343
csfd.cz	187	200

2/ Příklad vývoje impresí a kliků jednoho inzerentského účtu (campaign.png). Na základě grafů zkuste odhadnout obor daného inzerenta a popsat jednotlivá období v grafu.